

Rapport Final – Simulateur d'Estimation Immobilière

Contexte

Dans le cadre du projet **Smart Immo**, notre objectif est de développer un **simulateur intelligent d'estimation immobilière** pour le compte de l'entreprise **SalesHouses**, spécialisée dans les transactions immobilières (vente/achat).

Cet outil vise à fournir une estimation précise du prix d'un bien immobilier en se basant sur ses caractéristiques.

Étapes du Projet

1. Chargement & Exploration initiale

- Importation du dataset `appartements-data-db.csv`
 - Visualisation des premières lignes
 - Analyse des types de données et des valeurs manquantes
-

2. Prétraitement des données

Nettoyage & Transformation

- Conversion de la colonne `price` (objet) en `float`
- Suppression des colonnes `equipment` et `link`
- Uniformisation des noms de villes (`city_name`)
- Remplacement des valeurs manquantes :
 - Numériques : par la **médiane**

- Catégorielles : par "Unknown"
- Extraction des équipements en colonnes booléennes via `str.get_dummies(sep=',')`

Gestion des valeurs aberrantes

- Utilisation de l'IQR pour détecter les outliers sur `price`, `surface_area`, etc.
- Suppression des lignes contenant des valeurs extrêmes

Encodage des variables

- `LabelEncoder` pour `city_name`

Mise à l'échelle

- Utilisation de `StandardScaler` sur les colonnes numériques

Sélection des variables

- Suppression des variables fortement corrélées entre elles
- Sélection des variables corrélées au prix (seuil de 0.15)

3. Séparation des données

- Variable cible : `y = df["price"]`
 - Variables explicatives : `X` (features sélectionnées)
 - Division : 80% entraînement / 20% test
-



Entraînement des modèles

Modèle	MSE	RMSE	MAE	R ² Score	Temps (s)
Random Forest	0.02	0.14	0.09	0.4758	0.26
Gradient Boosting	0.02	0.14	0.09	0.4515	0.28
Linear Regression	0.02	0.15	0.10	0.4000	0.01
SVR	0.03	0.18	0.14	0.0590	0.07

✓ Validation croisée (5-fold)

Modèle	Cross-val R ² (moy ± std)
Linear Regression	0.3881 ± 0.0696
Random Forest	0.4196 ± 0.0476
SVR	-0.0009 ± 0.0194
Gradient Boosting	0.4039 ± 0.0662



Optimisation – GridSearchCV

- **Modèle testé** : Gradient Boosting Regressor
- **Meilleurs hyperparamètres** :

```
{  
  'learning_rate': 0.05,  
  'max_depth': 3,  
  'n_estimators': 100,  
  'subsample': 0.8  
}
```

Score R² après optimisation (cross-val) : 0.43



Conclusion

L'analyse et l'entraînement montrent que Random Forest et Gradient Boosting offrent les meilleures performances avec un R² supérieur à 0.45.

